

## homework 6

Topics in Statistics 1, Jieun Shin

2021.11.18

### 5.19

$X \sim \text{Exp}(\lambda_0)$  일 때,  $l = \mathbb{E}_{\lambda_0}[H(X)]$  를 추정하는데 최적의  $\lambda^*$  를 구하고자 한다.  $X$  가 지수족 분포를 따르는 확률변수이므로

$$\mathbb{E}_{\lambda_0} \left[ H(X) \left( \frac{\nabla c(\theta)}{c(\theta)} + T(X) \right) \right] = 0$$

을 만족하는  $\lambda$  가  $\lambda^*$  이다.

한 편, 모수  $\theta$  를 가지는 일반적인 지수족 분포  $g(x; \theta) = h(x) \exp(\eta(\theta)T(x))c(\theta)$  의 형태로 표현하면

$$\nabla \log g(x; \theta) = \nabla \eta(\theta)T(x) + \nabla \log c(\theta)$$

이고, 여기서  $\eta(\theta) = \theta$  일 때,

$$\nabla \log g(x; \theta) = T(x) + \frac{\nabla c(\theta)}{c(\theta)}$$

가 된다.

문제의  $f(x; \lambda) = \lambda \exp(-x/\lambda)$  를 지수족 분포의 형태에 따라 정리하면

$$\nabla \log f(x; \lambda) = \frac{1}{\lambda} - x$$

이므로 최적의 모수는 다음 과정에 의해 찾을 수 있다:

$$\begin{aligned} \mathbb{E}_{\lambda_0} \left[ H(X) \left( \frac{\nabla c(\lambda)}{c(\lambda)} + T(X) \right) \right] &= 0 \\ \mathbb{E}_{\lambda_0} \left[ H(X) \left( \frac{1}{\lambda} - X \right) \right] &= 0 \\ \mathbb{E}_{\lambda_0} \left[ \frac{H(X)}{\lambda} \right] - \mathbb{E}_{\lambda_0} [H(X)X] &= 0 \\ \frac{1}{\lambda} \mathbb{E}_{\lambda_0} [H(X)] &= \mathbb{E}_{\lambda_0} [H(X)X] \\ \therefore \lambda^* &= \frac{\mathbb{E}_{\lambda_0} [H(X)]}{\mathbb{E}_{\lambda_0} [H(X)X]} \end{aligned}$$

### 5.20

$X \sim \text{Weib}(\alpha, \lambda_0)$  일 때,  $l = \mathbb{E}_{\lambda_0}[H(X)]$  를 추정하는데 최적의  $\lambda^*$  를 구하고자 한다. 이 때,  $\lambda^*$  를 찾는 데 식

$$\mathbb{E}_{\theta_0} \left[ H(X) \left( \frac{\nabla c(\theta)}{c(\theta)} + T(X) \right) \right] = 0$$

을 이용해보자.

$X$ 는 분포  $f(x; \lambda) = \frac{\alpha}{\lambda^\alpha} x^{\alpha-1} e^{(-\frac{x}{\lambda})^\alpha}$  를 따른다. 여기서  $\theta = \lambda^\alpha$  로 놓으면

$$f(x; \theta) = \frac{\alpha}{\theta} x^{\alpha-1} e^{(-\frac{x^\alpha}{\theta})}$$

으로 표현된다.

$\log f(x; \theta)$ 의 편도함수는

$$\nabla \log f(x; \theta) = -\frac{1}{\theta} + x^\alpha \frac{1}{\theta^2}$$

이므로

$$c(\theta) = -\frac{1}{\theta}, \quad \nabla c(\theta) = \frac{1}{\theta^2}, \quad T(x) = x^\alpha,$$

이고,  $\lambda$ 에 대하여

$$c(\lambda) = -\frac{1}{\lambda^\alpha}, \quad \nabla c(\lambda) = \frac{1}{\lambda^{2\alpha}},$$

로 놓으면  $\lambda^*$  는 다음 과정에 의해 찾을 수 있다:

$$\begin{aligned} \mathbb{E}_{\lambda_0} \left[ H(X) \left( \frac{\nabla c(\lambda)}{c(\lambda)} + T(X) \right) \right] &= 0 \\ \mathbb{E}_{\lambda_0} \left[ H(X) \left( -\frac{1}{\lambda^\alpha} + X^\alpha \right) \right] &= 0 \\ -\frac{1}{\lambda^\alpha} \mathbb{E}_{\lambda_0} [H(X)] + \mathbb{E}_{\lambda_0} [H(X)X^\alpha] &= 0 \\ \frac{1}{\lambda^\alpha} \mathbb{E}_{\lambda_0} [H(X)] &= \mathbb{E}_{\lambda_0} [H(X)X^\alpha] \\ \therefore \lambda^* &= \left( \frac{\mathbb{E}_{\lambda_0} [H(X)]}{\mathbb{E}_{\lambda_0} [H(X)X^\alpha]} \right)^{\frac{1}{\alpha}} \end{aligned}$$

## 5.21

$X_1, \dots, X_n \sim i.i.d \text{ Exp}(\theta_0 = 1)$  라 하자.  $S(X) = \sum_{i=1}^n X_i$  라 할 때,  $l = \mathbb{E}[H(X)] = \mathbb{E}[I(S(X) \geq \gamma)]$  를 추정하는데 최적의  $\theta^*$  를 구하고자 한다.  $X_i, i = \dots, n$  가 rate가 1인 지수분포를 따르므로  $S(X)$  는 Gamma( $n, \theta$ ) 따르므로  $S(X)$  역시 지수족 분포를 따르는 확률변수이다. 따라서

$$\mathbb{E}_{\lambda_0} \left[ H(X) \left( \frac{\nabla c(\theta)}{c(\theta)} + T(X) \right) \right] = 0$$

을 만족하는  $\theta$  가  $\theta^*$  이다.

문제의  $f(s; \theta) = \frac{1}{\Gamma(n)\theta^n} s^{n-1} e^{-\frac{s}{\theta}}$  의 편도함수  $\log f(x; \theta)$  는

$$\nabla \log f(s; \theta) = -\frac{n}{\theta} + \frac{s}{\theta^2}$$

이므로

$$c(\theta) = -\frac{1}{\theta}, \quad \nabla c(\theta) = \frac{1}{\theta^2}, \quad T(s) = s, T(x) = \sum_{i=1}^n x_i$$

로부터  $\theta^*$  를 다음 과정에 의해 찾을 수 있다.

$$\begin{aligned}
& \mathbb{E}_{\theta_0} \left[ H(X) \left( \frac{\nabla c(\theta)}{c(\theta)} + T(X) \right) \right] = 0 \\
& \mathbb{E}_{\theta_0} \left[ H(X) \left( -\frac{n}{\theta} + \sum_{i=1}^n X_i \right) \right] = 0 \\
& -\frac{n}{\theta} \mathbb{E}_{\theta_0} [H(X)] + \mathbb{E}_{\theta_0} \left[ H(X) \sum_{i=1}^n X_i \right] = 0 \\
& \mathbb{E}_{\theta_0} [H(X)] = \theta \mathbb{E}_{\theta_0} \left[ H(X) \frac{1}{n} \sum_{i=1}^n X_i \right] \\
& \therefore \theta^* = \frac{\mathbb{E}_{\theta_0} [H(X)]}{\mathbb{E}_{\theta_0} [H(X) \bar{X}]} = \frac{\mathbb{E}_{\theta_0} [I(S(X) \geq \gamma)]}{\mathbb{E}_{\theta_0} [I(S(X) \geq \gamma) \bar{X}]}
\end{aligned}$$

## 5.22

함수  $G(z) = \frac{1}{\lambda_0} z^{\frac{1}{\alpha}}$  와  $\tilde{H}(z) = H(G(z))$  를 정의하자.

(a)  $G(Z)$  의 cdf를 구하면 다음과 같다:

$$F(G(Z)) = \mathbb{P}(G(Z) \leq z) = \mathbb{P}\left(\frac{1}{\lambda_0} Z^{\frac{1}{\alpha}} \leq z\right) = \mathbb{P}(Z \leq (\lambda_0 z)^{\alpha}) = \int_{-\infty}^{(\lambda_0 z)^{\alpha}} e^{-t} dt = 1 - e^{-(\lambda_0 z)^{\alpha}}$$

이는 Weib( $\alpha, \lambda_0$ ) 의 cdf인  $1 - e^{-(\lambda_0 z)^{\alpha}}$  와 동일하므로  $G(Z) \sim \text{Weib}(\alpha, \lambda_0)$  이다.

(b)  $l = \mathbb{E}_X [H(X)] = \mathbb{E}_Z [H(G(Z))] = \mathbb{E}_Z [\tilde{H}(Z)]$  의 TLR 방법의 추정치는  $\hat{l} = \frac{1}{N} \sum_{i=1}^N \tilde{H}(Z) W(Z_k; 1, \eta)$  이다. 여기서  $W(Z_k; 1, \eta) = \frac{h(Z_k; 1)}{h(Z_k; \eta)}$  로 정의되며,  $Z$  는  $h(z_k; \eta)$  에서 생성된다. 즉,  $h(z_k; \eta)$  는 rate가  $\eta$  인 지수분포이다.

(c) 최적의  $\theta^*$  는  $\mathbb{E}_\eta [\tilde{H}(Z) W(Z_k; 1, \eta) \log h(Z; \theta)]$  을 최대화하는  $\theta$  와 같다:

$$\theta^* = \max_\theta \mathbb{E}_\eta [\tilde{H}(Z) W(Z_k; 1, \eta) \log h(Z; \theta)]$$

위 기댓값을  $\theta$ 에 대해 미분하여 0이 되는  $\theta$  를 찾자:

$$\mathbb{E}_\eta [\tilde{H}(Z) W(Z_k; 1, \eta) \nabla \log h(Z; \theta)] = 0$$

$h(z; \theta) = \theta e^{-\theta z}$  이므로  $\nabla \log h(z; \theta) = \frac{1}{\theta} - z$  이다. 따라서 최적의  $\theta^*$  는 다음과 같이 정해진다:

$$\begin{aligned}
& \mathbb{E}_\eta [\tilde{H}(Z) W(Z; 1, \eta) \nabla \log(\theta e^{-\theta Z})] = 0 \\
& \mathbb{E}_\eta \left[ \tilde{H}(Z) W(Z; 1, \eta) \left( \frac{1}{\theta} - Z \right) \right] = 0 \\
& \frac{1}{\theta} \mathbb{E}_\eta [\tilde{H}(Z) W(Z; 1, \eta)] = \mathbb{E}_\eta [\tilde{H}(Z) Z W(Z; 1, \eta)] \\
& \therefore \theta^* = \frac{\mathbb{E}_\eta [\tilde{H}(Z) W(Z; 1, \eta)]}{\mathbb{E}_\eta [\tilde{H}(Z) Z W(Z; 1, \eta)]}
\end{aligned}$$

```
library(dplyr)
library(gsignal)
library(nimble)
```

## 6.2

목표분포를  $f \sim N(10, 1)$  라 하고, 후보값  $Y$ 은 제안분포  $N(x, 0.01)$ 을 따른다고 할 때, 목표분포를 따르는 확률변수  $X$ 를 생성하기 위해 다음의 random walk 알고리즘을 구현하자.

- (1)  $N(0, 0.01)$ 로부터 초기값  $x_0$ 을 생성한다.
- (2)  $t = 1, \dots, N = 5000$ 에 대해 다음을 반복한다.
  - (a)  $Z = Y - X_t \sim N(0, 0.01)$ 을 생성한다.
  - (b)  $U \sim U(0, 1)$ 을 생성한다.
  - (c)  $\alpha = \min\{\frac{f(Y)}{f(X_t)}, 1\}$ 에 대하여 만약  $U \leq \alpha$ 이면  $X_{t+1} = Y$ 로 놓고, 그렇지 않으면  $X_{t+1} = X_t$ 로 놓는다.

```
RandomWalk6.2 = function(N, sigma){
  # initialize
  x = rnorm(1, 0, sigma)

  out_x = x  # outcome

  for(t in 1:N){
    t = t + 1

    z = rnorm(1, 0, sigma)
    y = x + 2 * z
    a = min(dnorm(y, 10, 1) / dnorm(x, 10, 1), 1)

    u = runif(1, 0, 1)
    x_new = ifelse(u <= a, y, x)
    out_x[t] = x_new

    x = x_new
  }

  return(out_x)
}
```

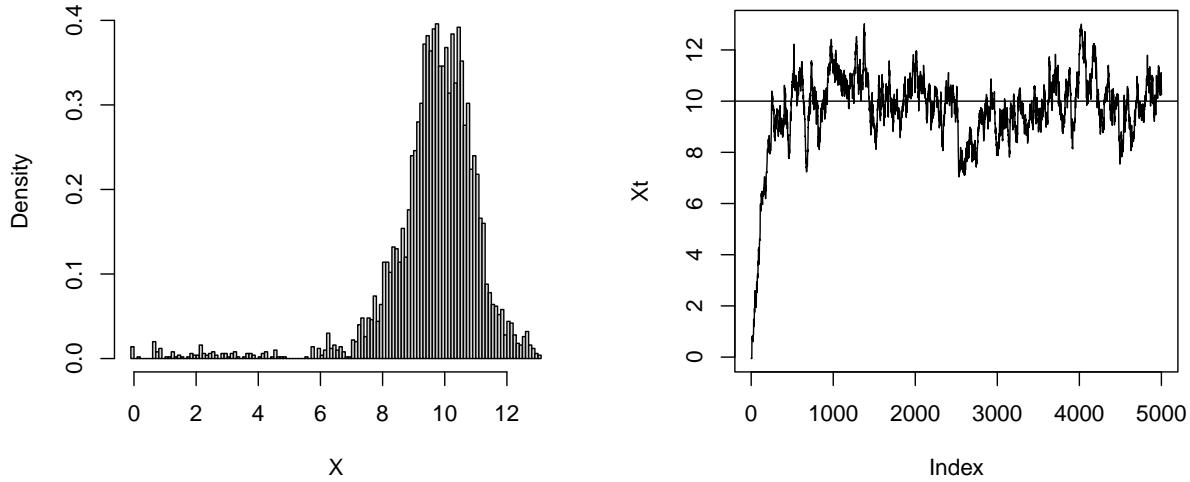
생성된 모든 프로세스  $\{X_t\}$ 들의 히스토그램과 생성 과정을 보면 burn-in 기간이 지난 뒤에는 정상 상태에 도달한 것을 확인할 수 있다.

```
set.seed(123)
N = 5000

X = RandomWalk6.2(N = N, sigma = 0.1)
hist(X, breaks = 100, main = "For all periods", xlab = "X", freq = FALSE)

plot(X, type = 'l', ylab = "Xt")
abline(h = 10)
```

### For all periods

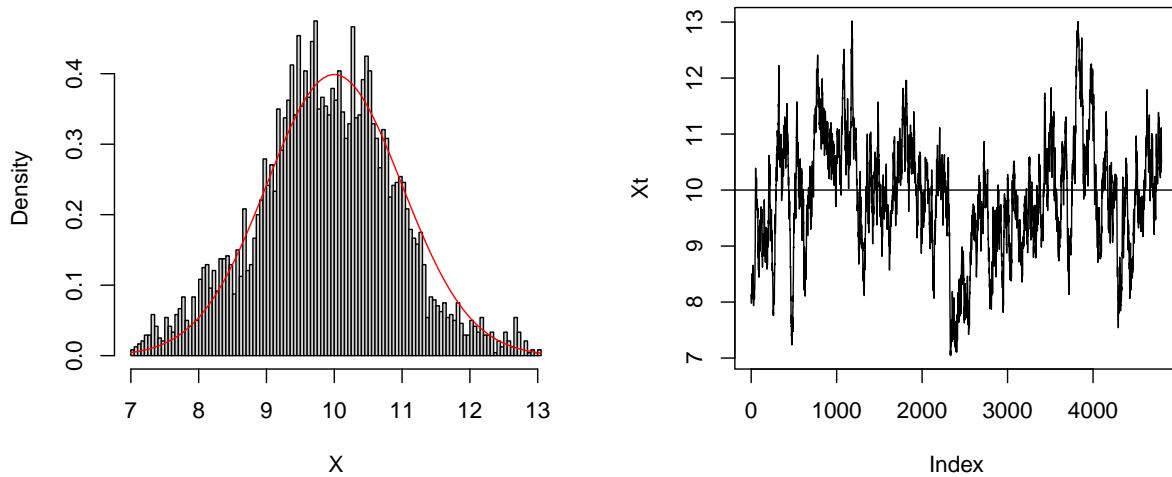


이에 따라 burn-in 기간을 200으로 잡아  $X$  가 생성한 분포와 목표분포  $N(10, 1)$ 을 그림을 통해 비교해보았다.  $X$ 의 분포가 완전히 부드럽지는 않지만 목표분포와 비교적 비슷하게 생성됨을 확인할 수 있으며, 프로세스 역시 정상상태에 도달함을 확인할 수 있다.

```
# burn-in 기간에 속하는 샘플 제거
k = 200
hist(X[k:N] , breaks = 100, main = "After removal of burn-in period", xlab = "X", freq = FALSE)
curve(dnorm(x, 10, 1), add = T, col = "red")

plot(X[k:N], type = 'l', ylab = "Xt")
abline(h = 10)
```

### After removal of burn-in period



### 6.3

마코프 체인으로 생성한 프로세스는 다음 시점의 값이 전 시점에 의존하므로 독립이지 않는데, 이를 보여주는 것이 교차공분산이다.

각  $\sigma^2 = 0.1, 0.5, 1, 2$ 에 대한 추정된 공분산 함수의 dotplot을 그려보면 아래의 그래프 결과와 같다. 그래프의  $k$ 는  $X_0$  시점과  $k$  시점 만큼 떨어진  $X_k$  시점을 의미하며,  $R(k)$ 은  $X_0$ 부터  $X_k$  사이의 교차공분산을 의미한다.  $R(k) = 0$ 에 가까울수록 상관성이 작아짐을 의미한다. 그래프를 보면 모든  $\sigma^2$ 에 대해 가까운 시점과의 교차공분산은 크고 먼 시점을 포함할수록 교차공분산은 작아진다. 즉, 가까운 시점과는 상관이 크며 멀리 떨어진 시점일수록 작은 상관이 존재함을 의미한다.

또한 제안분포인 정규분포의 분산을 바꾸어 모의실험을 진행하였다. 아래 그래프에서 분산이 가장 작은  $\sigma^2 = 0.1$  일 때 상관이 작아지기 위해 필요한 시점의 차이가 커야 하며 (약 200),  $\sigma^2 = 0.1$  이상에서는 상관이 작아지기 위해 필요한 시점의 차이가 비교적 작다 (약 50 이내).

그 이유는 정규분포의 분산이 작을수록 다음 시점의 값을 전 시점의 근처에서 선택할 가능성이 크기 때문에 정규분포의 분산이 클 때보다 가까운 시점과의 상관성이 높기 때문으로 보인다.

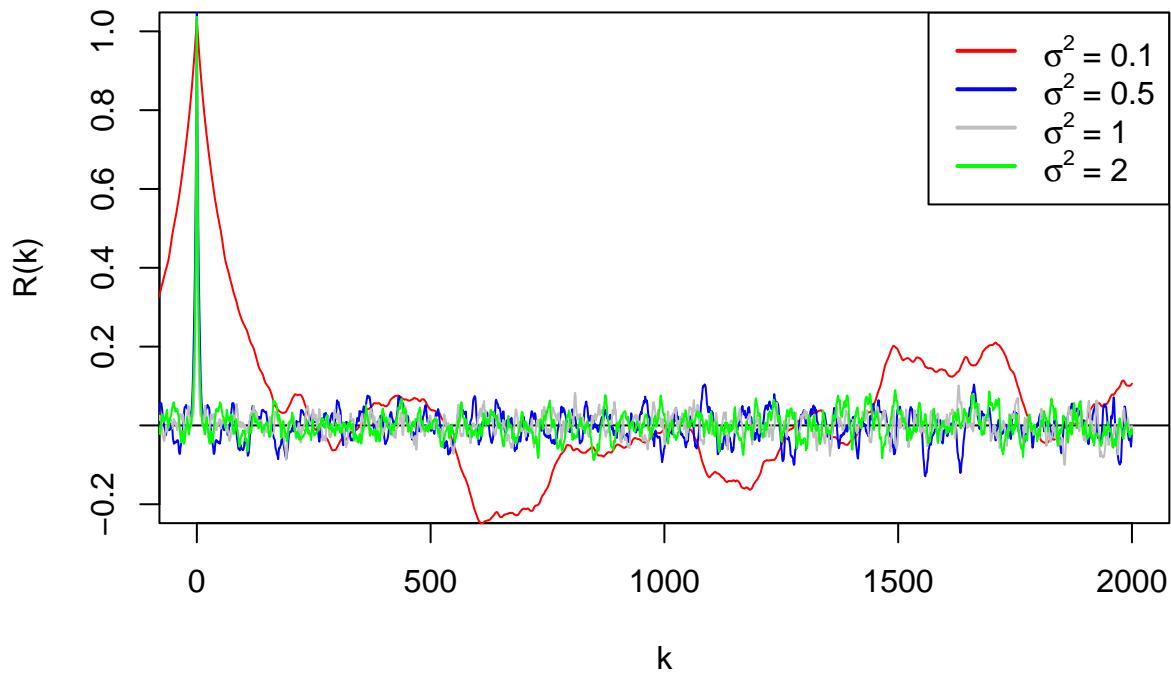
```
col_list = c("red", "blue", "grey", "green")
Mlag = 2000

# make empty plot
plot(1:k, seq(0, 1, length.out = k), type = "n",
      xlab = "k", ylab = "R(k)", xlim = c(0, Mlag), ylim = c(-0.2, 1),
      main = "dotplot of the covariance function")
abline(h = 0)

# draw histogram according to changing the sigma
S = c(0.1, 0.5, 1, 2)
i = 0
for(s in S){
  i = i + 1
  X = RandomWalk6.2(N = N, sigma = s)
  XCOV = xcov(X[k:N], maxlag = Mlag, scale = "unbiased")
  points(XCOV$lags, XCOV$C, type = "l", xlim = c(0, Mlag), col = col_list[i], lwd = 1)
}

legend("topright", lwd = 2,
       legend = c(as.expression(bquote(sigma^2 ~ "= 0.1")),
                  as.expression(bquote(sigma^2 ~ "= 0.5")),
                  as.expression(bquote(sigma^2 ~ "= 1")),
                  as.expression(bquote(sigma^2 ~ "= 2"))),
       col = col_list)
```

## dotplot of the covariance function



### 6.4

목표분포를  $f \sim \text{Exp}(1)$  라 하고, 후보값  $Y$ 은 제안분포  $\text{Exp}(\lambda)$ 을 따른다고 할 때, 목표분포를 따르는 확률변수  $X$ 를 생성하기 위해 다음의 independence sampler 알고리즘을 구현하자.

- (1) 초기값  $x_0 = 1$ 을 부여한다.
- (2) 각  $\lambda \in \{0.2, 1, 2, 5\}$ 에 대하여  $t = 1, \dots, N = 100,000$  번 다음을 반복한다.
  - (a)  $Y \sim \text{Exp}(\lambda)$ 을 생성한다.
  - (b)  $U \sim U(0, 1)$ 을 생성한다.
  - (c)  $\alpha = \min\left\{\frac{f(Y)g(X)}{f(X_t)g(Y)}, 1\right\}$ 에 대하여 만약  $U \leq \alpha$ 이면  $X_{t+1} = Y$ 로 놓고, 그렇지 않으면  $X_{t+1} = X_t$ 로 놓는다.

```
IndepSampler6.4 = function(N, lambda){
  # initialize
  x = 1

  out_x = x  # outcome

  for(t in 1:N){
    t = t + 1
    y = rexp(1, lambda)
    if (runif(1) < min(f(y)*g(x)/f(x)*g(y), 1))
      x = y
    out_x[t] = x
  }
}
```

```

num = dexp(y, 1) * dexp(x, lambda)
den = dexp(x, 1) * dexp(y, lambda)
a = min( num / den, 1)

u = runif(1, 0, 1)

x_new = ifelse(u <= a, y, x)

out_x[t] = x_new

x = x_new
}

return(out_x)
}

```

- (a) 각  $\lambda = 0.2, 1, 2, 5$ 에 대해, independence sampler로 구한  $X$ 의 분포와 목표분포  $\text{Exp}(1)$ 를 비교해보자. 히스토그램은 burn-in 기간 200을 제외하여 그렸으며, 생성된 모든 프로세스  $\{X_t\}$ 들의 히스토그램과 생성 과정을 보면 burn-in 기간이 지난 후 정상 상태에 도달한 것을 확인할 수 있다.

```

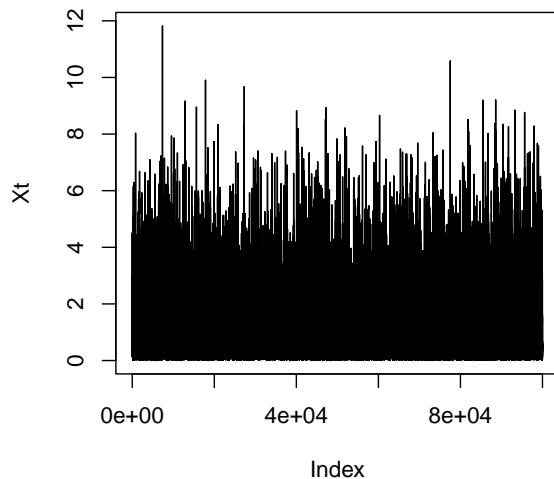
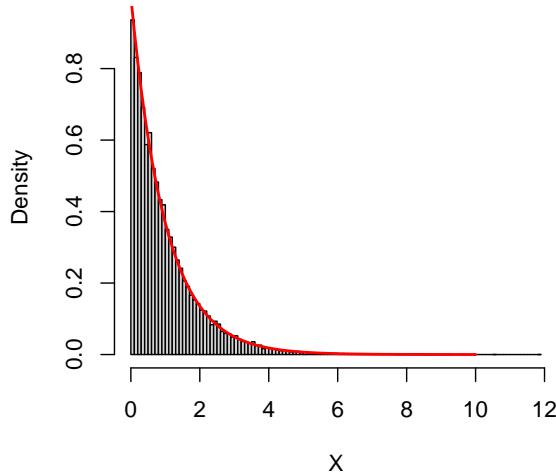
set.seed(123)
N = 10^5
k = 200
Lambdas = c(0.2, 1, 2, 5)

# draw a graph
for(l in Lambdas){
  X = IndepSampler6.4(N = N, lambda = l)
  hist(X[k:N], breaks = 100, main = paste0("lambda=", l),
        xlab = "X", freq = FALSE)
  curve(dexp(x, 1), 0, 10, col = "red", lwd = 2, add = TRUE)

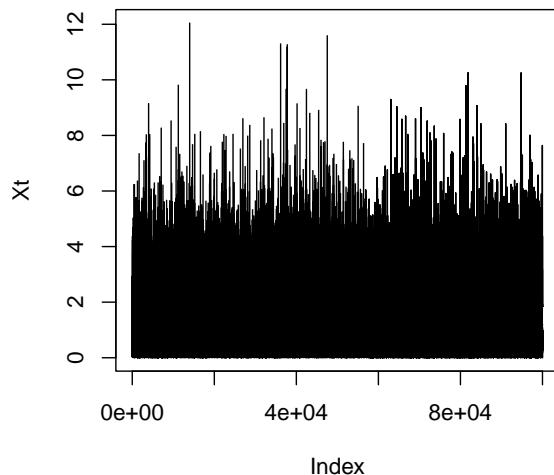
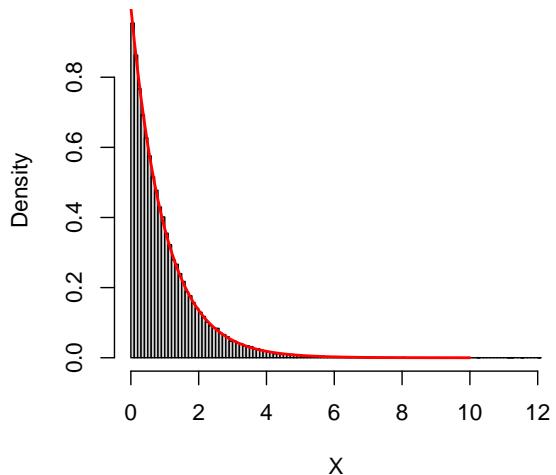
  plot(X, type = 'l', ylab = "Xt")
}

```

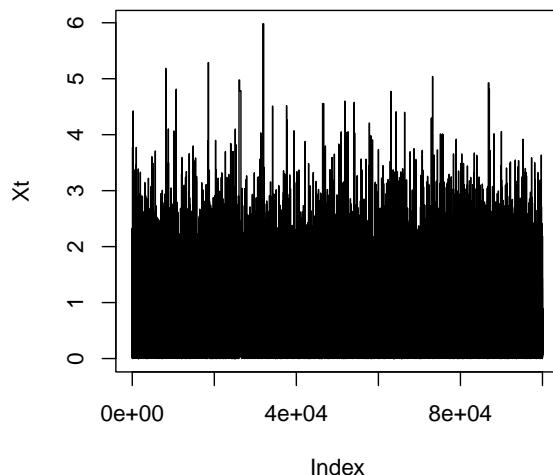
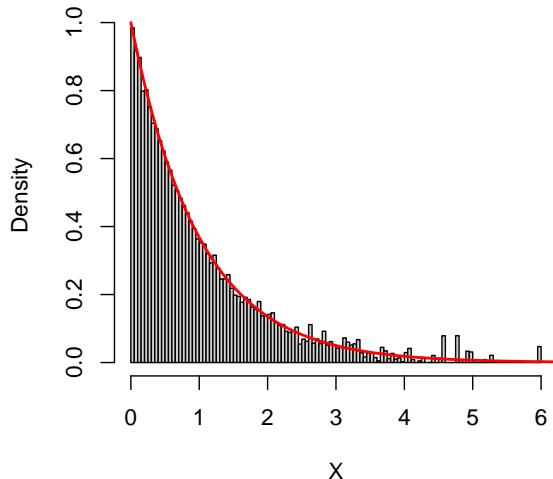
**lambda=0.2**



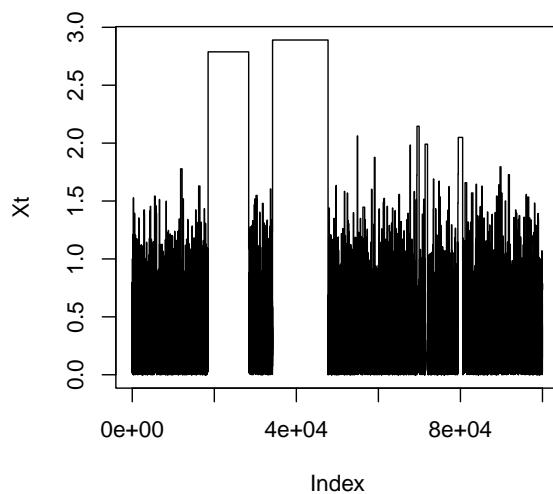
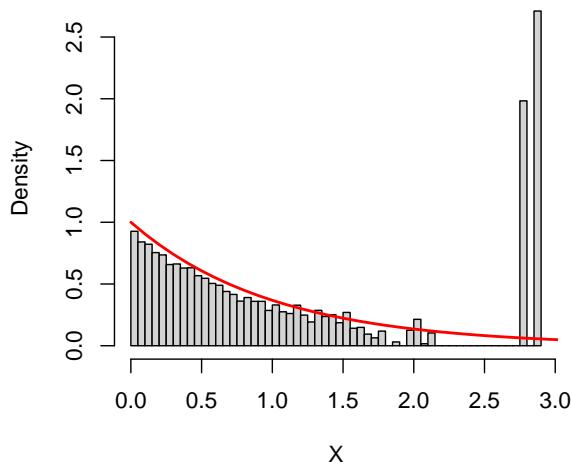
**lambda=1**



**lambda=2**



**lambda=5**



- (b) 각  $\lambda$ 에 대해 20번 반복하여 얻은 covariance function과 표본 평균을 그래프로 그려보았다. 먼저 각  $\lambda$ 에 대한 covariance function을 보면  $\lambda$ 가 커질수록 더 작은 범위 내에서 다음 시점 값은 선택한다. 즉,  $\lambda$ 가 가장 작은 경우인  $\lambda = 0.2$ 에서는  $[0, 6]$  사이의 비교적 넓은 범위에서 값이 분포하여 적은 시점 (약  $k = 50$ )내에 상관이 작아지지만,  $\lambda$ 가 가장 큰 경우인  $\lambda = 5$ 에서는 생성한 값들이  $[0, 1.5]$ 의 좁은 범위에 분포하기 때문에 상관이 작아지기 위해 비교적 많은 시점 (약  $k = 100$ )이 필요하다.

제안분포가  $\lambda > 2$ 를 가질 때 더 0과 가까우며 오른쪽으로 꼬리가 길고 가늘긴 분포를 가진다. 따라서 다음 시점의 값이 전 시점의 값과 매우 가까운 지점에서 생성될 가능성이 높기 때문에 시차가 작은 샘플 사이의 상관성이 높게 나타나게 된다.

```
Xmean_list = list() # to save sample mean output
j = 0
for(l in Lambdas){
```

```

j = j + 1

# calculate the 20 sample mean
Xlist = list()
Xmean = c()
for(i in 1:20){
  Xlist[[i]] = IndepSampler6.4(N = N, lambda = 1)
  Xmean[i] = mean( Xlist[[i]] )
}

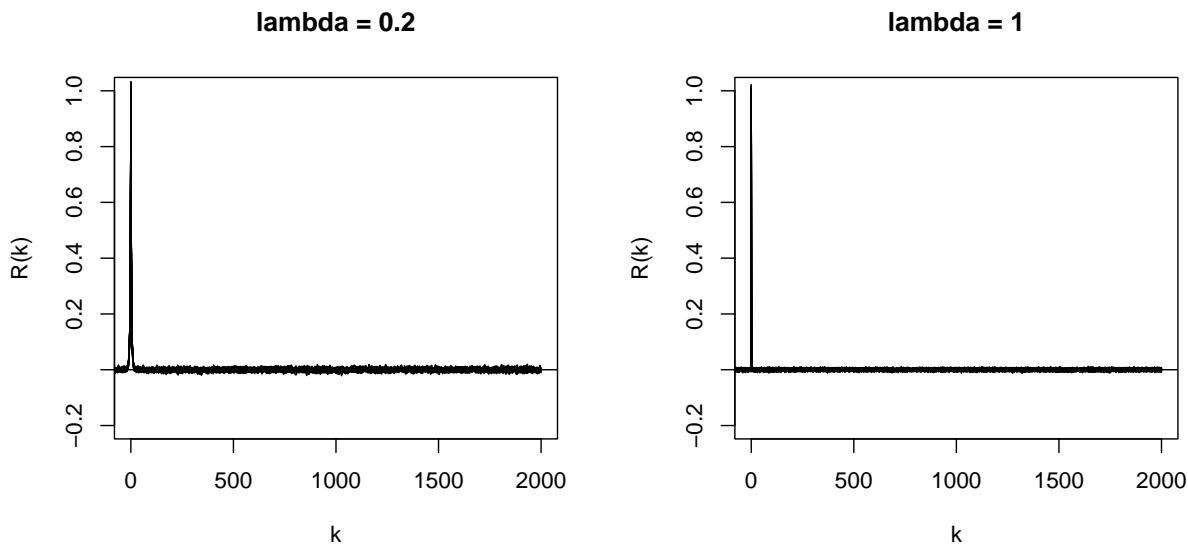
Xmean_list[[j]] = Xmean

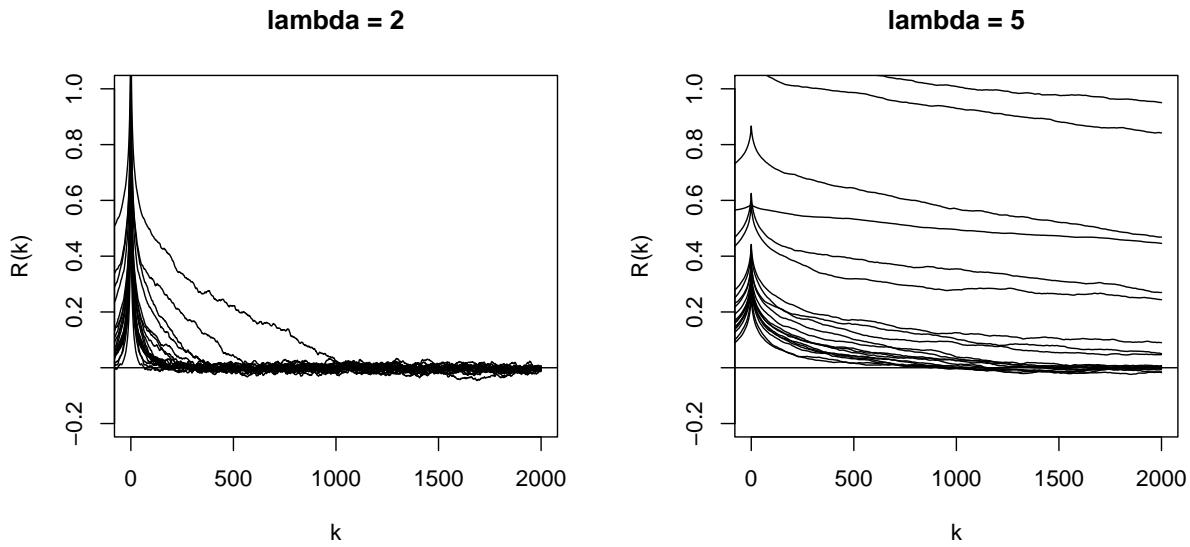
# draw the estimated covariance function
# make blank plot
plot(1:k, seq(0, 1, length.out = k), type = "n", main = paste0("lambda = ", 1),
      xlab = "k", ylab = "R(k)", xlim = c(0, Mlag), ylim = c(-0.2, 1))
abline(h = 0)

for(i in 1:20){
  XCOV = xcov(Xlist[[i]][k:N], maxlag = Mlag, scale = "unbiased")
  points(XCOV$lags, XCOV$C, type = "l", xlim = c(0, Mlag), lwd = 1)
}

rm(Xlist)
}

```

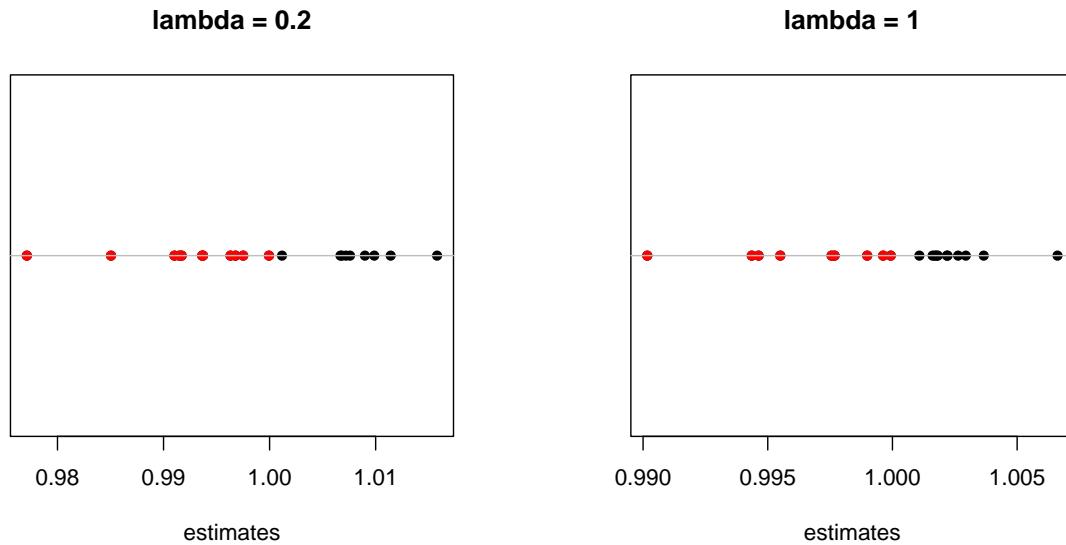


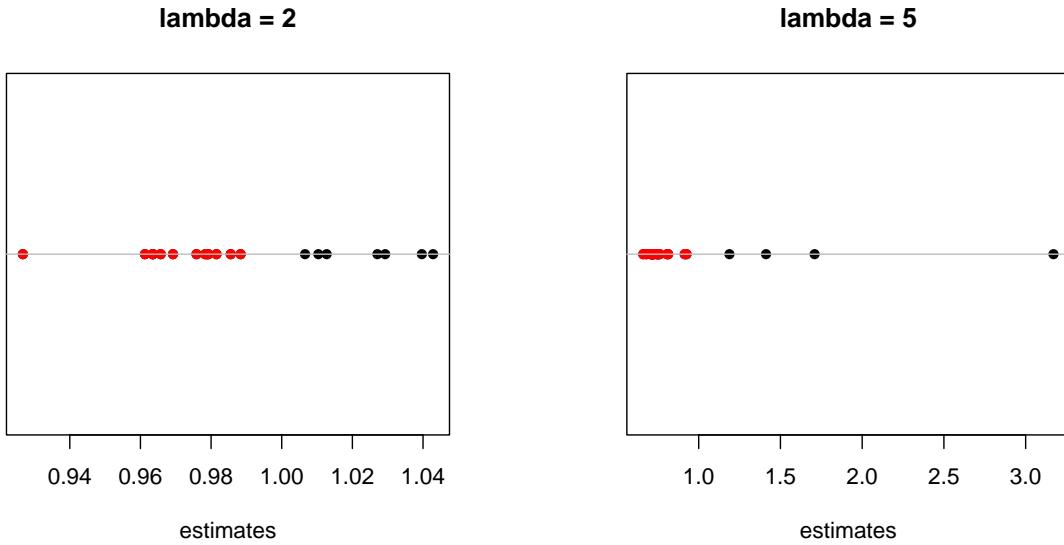


다음으로 각  $\lambda$ 에 대해 20번 반복하여 얻은 표본 평균을 그래프로 그려보았다.  $\lambda < 2$ 인 경우 대체로 표본평균이 참 값인 1 근처에서 나타나지만,  $\lambda = 5$ 로 큰 경우 표본 평균이 1 이하의 값을 많이 가지며 큰 값에서 뛰는 경우도 발생한다. 따라서  $\lambda = 5$ 일 때는 목표분포에 적절히 도달하지 못한다고 볼 수 있다.

```
# draw the sample mean dotplot
for(i in 1:4){
  plot(x = Xmean_list[[i]], y = rep(1, 20), pch = 16,
    xlab = "estimates", ylab = "", main = paste0("lambda = ", Lambdas[i]), yaxt = 'n')

  xx = Xmean_list[[i]][Xmean_list[[i]] <= 1]
  points(x = xx, y = rep(1, length(xx)), pch = 16, col = "red")
  abline(h = 1, col = "grey")
}
```





제안분포를  $\lambda = 5$ 로 줄 때, 표본 평균이 1이하인갯수는 16개로 나타났다.

```
# lambda = 5일 때 sample mean이 1 이하인 것의 갯수
Xmean_list[[4]][Xmean_list[[4]] <= 1] %>% length
```

```
## [1] 16
```

## 6.5

제안 상태  $Y$ 에 대하여 증분  $Z = Y - X_t$ 이 DoubleExp( $\lambda$ )을 따른다고 할 때, 목표분포  $f \sim \text{Exp}(1)$ 를 따르는 확률변수  $X$ 를 생성하기 위한 다음의 random walk 알고리즘을 구현하자.

- (1)  $N(0, 0.01)$ 로부터 초기값  $x_0$ 을 생성한다.
- (2) 각  $\lambda \in \{0.1, 2, 5, 20\}$ 에 대하여  $t = 1, \dots, N = 100,000$  번 다음을 반복한다.
  - (a)  $Z = Y - X_t \sim \text{DoubleExp}(\lambda)$ 을 생성한다.
  - (b)  $U \sim U(0, 1)$ 을 생성한다.
  - (c)  $\alpha = \min\left\{\frac{f(Y)}{f(X_t)}, 1\right\}$ 에 대하여 만약  $U \leq \alpha$ 이면  $X_{t+1} = Y$ 로 놓고, 그렇지 않으면  $X_{t+1} = X_t$ 로 놓는다.

```
RandomWalk6.5 = function(N, lambda){
  # initialize
  x = 1
  out_x = x  # outcome

  for(t in 1:N){
    t = t + 1

    z = rdepx(n = 1, location = 0, rate = lambda)
    y = x + z
```

```

a = min(dexp(y, 1) / dexp(x, 1), 1)
u = runif(1, 0, 1)

x_new = ifelse(u <= a, y, x)

out_x[t] = x_new
x = x_new
}

return(out_x)
}

```

각  $\lambda = 0.1, 1, 5, 20$ 에 대해, random walk로 구한  $X$ 의 분포와 목표분포  $\text{Exp}(1)$ 를 비교해보자. 히스토그램은 burn-in 기간 200을 제외하여 그렸으며, 생성된 모든 프로세스  $\{X_t\}$ 들의 히스토그램과 생성 과정을 보면 burn-in 기간이 지난 후 정상 상태에 도달한 것을 확인할 수 있다.

또한 히스토그램을 통해 random walk의  $\lambda = 20$  일 때, independence sampler의  $\lambda = 5$ 에 비해 훨씬 더 안정적으로 목표분포에 도달함을 확인하였다. 이는 random walk의 sample mean의 1 이하의 값이 12개로 independence sampler의 16개보다 적은 것에서도 알 수 있다.

covariance function를 보면 random walk의 공분산이 조금 더 큰 경향이 있지만  $\lambda$ 가 클 때는 random walk의 공분산이 independence sampler보다 전체적으로 뺏지 않는 모습을 보인다.

아래의 결과들은 independence sampler의 과정에서 행한 동일한 결과를 프린트한 것이며, 각 결과에 대한 설명은 independence sampler 결과와 비교함으로 대체한다.

```

set.seed(123)

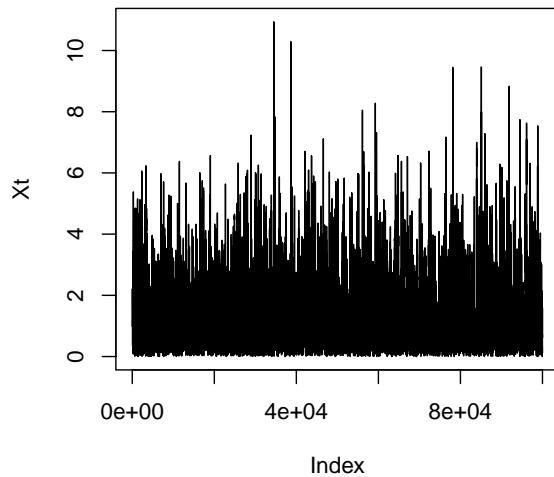
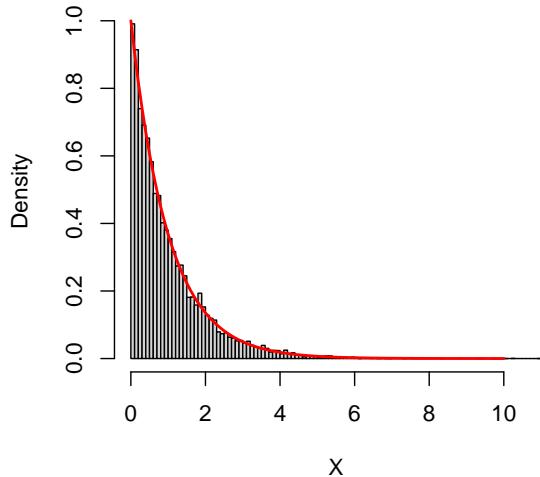
Lambdas = c(0.1, 1, 5, 20)
# draw a graph

for(l in Lambdas){
  X = RandomWalk6.5(N = N, lambda = l)
  hist(X[k:N], breaks = 100, main = paste0("lambda = ", l),
        xlab = "X", freq = FALSE)
  curve(dexp(x, 1), 0, 10, col = "red", lwd = 2, add = TRUE)

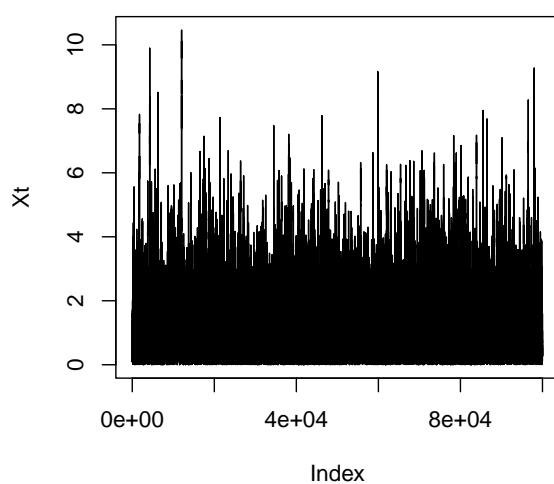
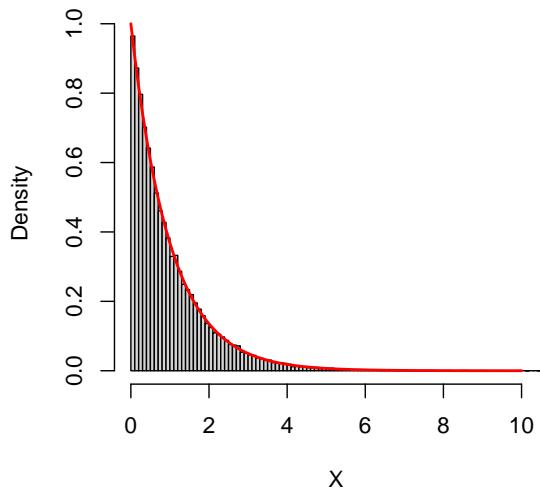
  plot(X, type = 'l', ylab = "Xt")
}

```

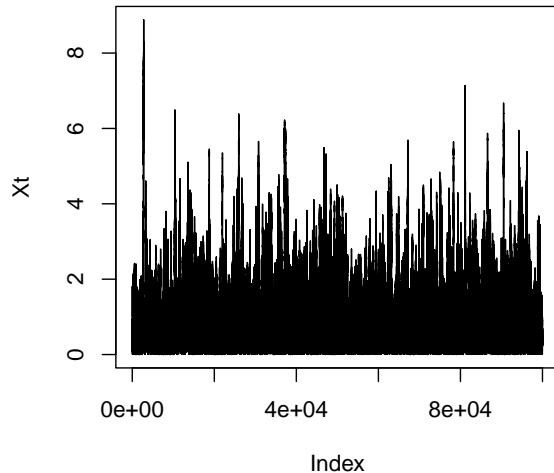
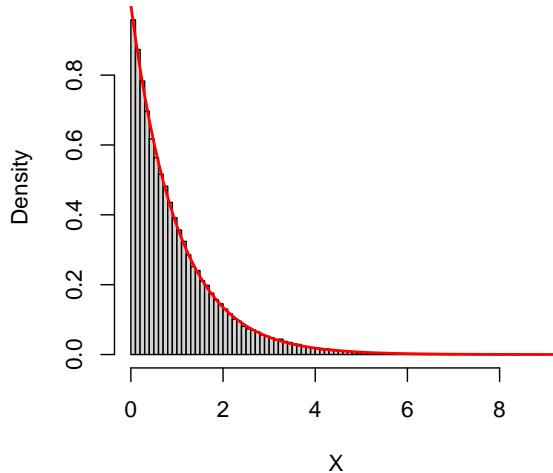
**lambda = 0.1**



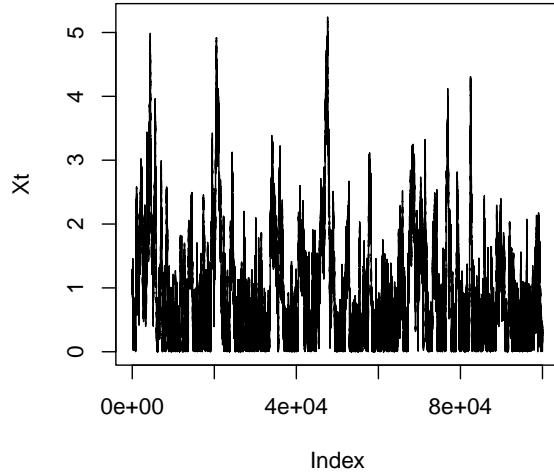
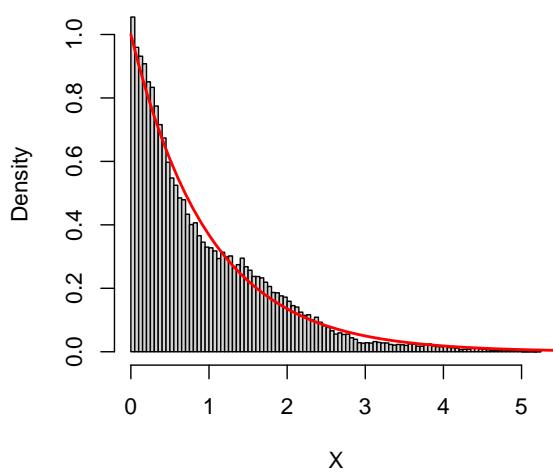
**lambda = 1**



**lambda = 5**



**lambda = 20**



- covariance function

```
Xmean_list = list() # to save sample mean output

j = 0
for(l in Lambdas){
  j = j + 1

  # calculate the 20 sample mean
  Xlist = list()
  Xmean = c()
  for(i in 1:20){
    Xlist[[i]] = RandomWalk6.5(N = N, lambda = 1)
    Xmean[i] = mean( Xlist[[i]] )
```

```

}

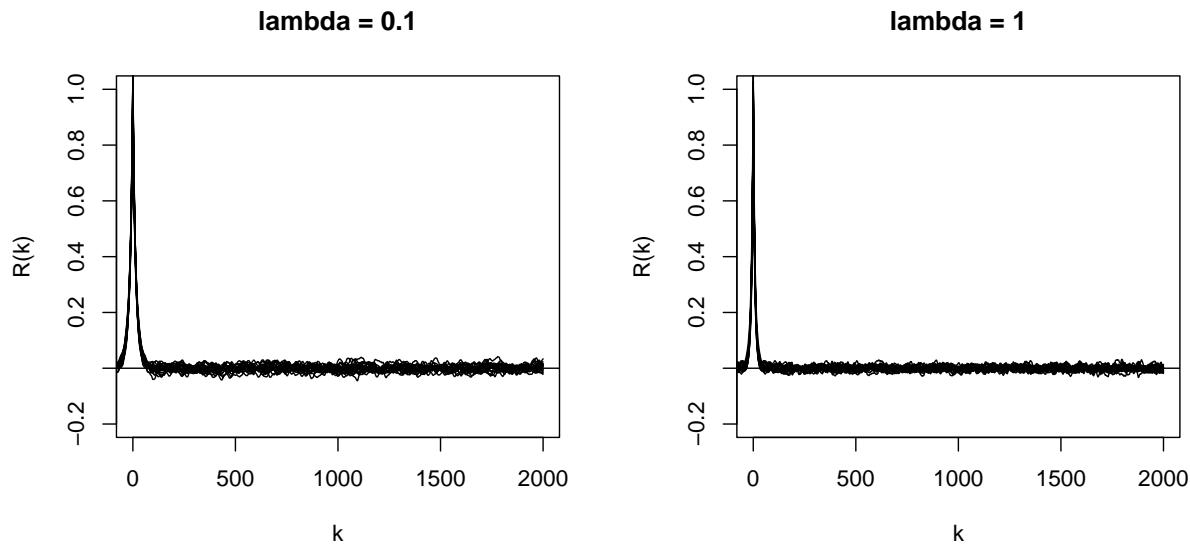
Xmean_list[[j]] = Xmean

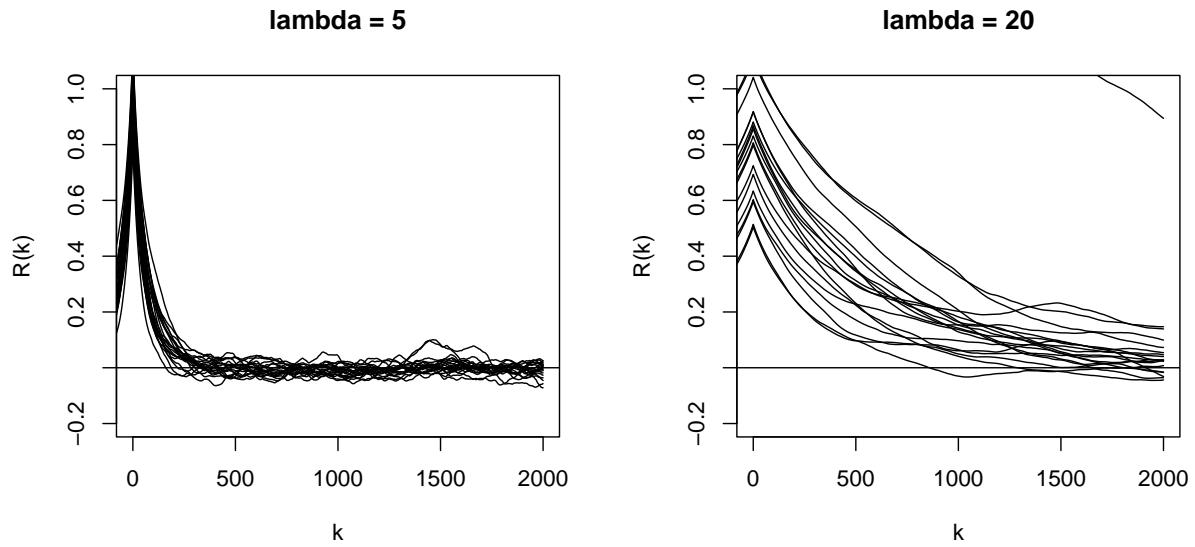
# draw the estimated covariance function
# make blank plot
plot(1:k, seq(0, 1, length.out = k), type = "n", main = paste0("lambda = ", l),
      xlab = "k", ylab = "R(k)", xlim = c(0, Mlag), ylim = c(-0.2, 1))
abline(h = 0)

for(i in 1:20){
  XCOV = xcov(Xlist[[i]][k:N], maxlag = Mlag, scale = "unbiased")
  points(XCOV$lags, XCOV$C, type = "l", xlim = c(0, Mlag), lwd = 1)
}

rm(Xlist)
}

```

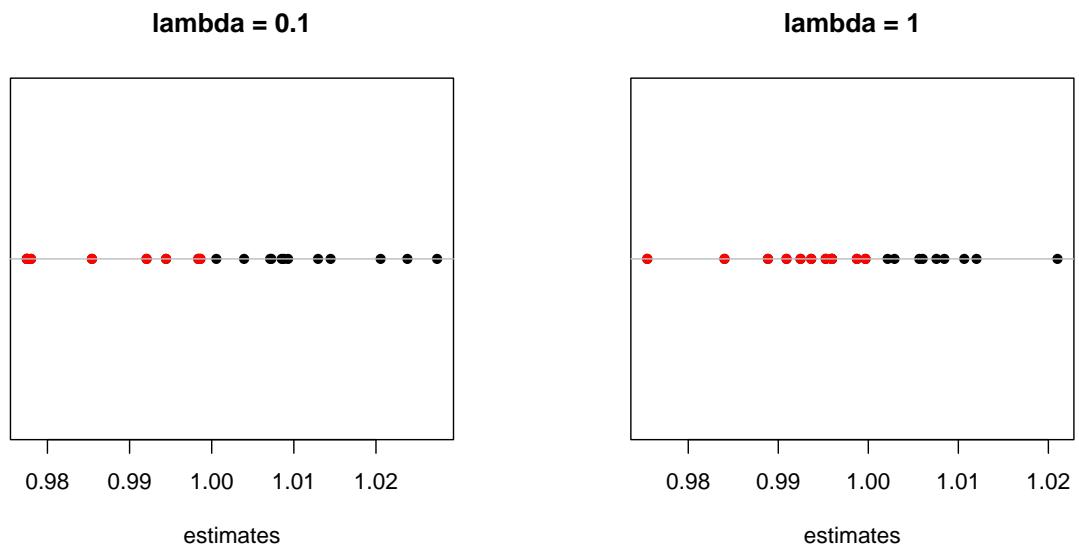




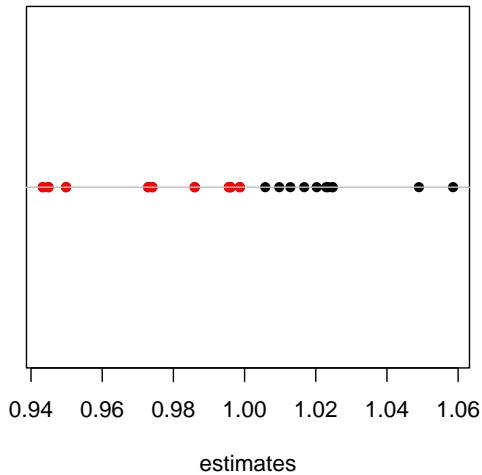
- dotplot of 20 sample mean

```
# draw the sample mean dotplot
for(i in 1:4){
  plot(x = Xmean_list[[i]], y = rep(1, 20), pch = 16,
    xlab = "estimates", ylab = "", main = paste0("lambda = ", Lambdas[i]), yaxt = 'n')

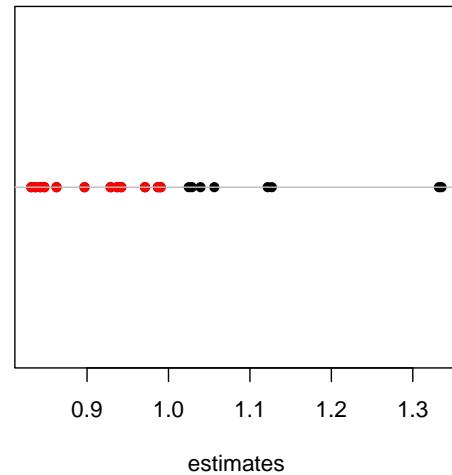
  xx = Xmean_list[[i]][Xmean_list[[i]] <= 1]
  points(x = xx, y = rep(1, length(xx)), pch = 16, col = "red")
  abline(h = 1, col = "grey")
}
```



**lambda = 5**



**lambda = 20**



- lambda = 5 일 때 sample mean이 1 이하인 것의 갯수

```
# lambda = 5 일 때 sample mean이 1 이하인 것의 갯수  
Xmean_list[[4]][Xmean_list[[4]] <= 1] %>% length
```

```
## [1] 12
```